

인공지능 신약 개발 아이디어 공모전

： **MHC-Peptide Binding Affinity Prediction** ：

신약 후보 물질 스크리닝 모델

목차

Index

⋮

01

제안이유

02

제안내용

03

활용 방안
및 기대효과


04

참고문헌

⋮

01 제안이유

- MHC는 면역계에서 펩타이드(항원)와 결합해 T세포가 면역반응을 일으키도록 돕는 역할
- MHC-Peptide 간 충분한 결합력(Binding Affinity)이 있어야 T세포가 효과적으로 인식하고 면역 반응을 활성화 함
- MHC-Peptide 간 결합력 예측을 통해 많은 신약 후보 물질 필터링 가능 → 신약 개발



Structure of HLA-A3 with 9-mer peptide

01 제안이유

■ MHC polymorphism → time & cost consuming

□ MHC-Peptide 면역 반응 관련 데이터가 축적되며, Computational 기반 연구 접근에 용이해짐

- in-vitro → in silico

Database	Brief	URL	References
IMGT/HLA	HLA sequences	http://www.ebi.ac.uk/imgt/hla/	[9]
IEDB	MHC binding peptides, ligands and epitopes	http://www.immuneepitope.org/	[21]
SYFPEITHI	MHC ligands and peptide motif	http://www.syfpeithi.de/	[42]
IPD-MHC	MHC sequences of diverse species	http://www.ebi.ac.uk/ipd/mhc/	[61]
MHCBN	MHC/TAP binding peptides and T-cell epitopes	http://www.imtech.res.in/raghava/mhcbn/	[62]
EPIMHC	MHC ligands	http://bio.dfci.harvard.edu/epimhc/	[63]
LANL-HIV	HIV T-cell epitopes	http://www.hiv.lanl.gov/content/immunology/index	—

MHC-peptide binding 예측 관련 주요 데이터베이스

01 제안이유

■ MHC polymorphism → time & cost consuming

□ MHC-Peptide 면역 반응 관련 데이터가 축적되며, Computational 기반 연구 접근에 용이해짐

- in-vitro → in silico

Database	Brief	URL	References
IMGT/HLA	HLA sequences	http://www.ebi.ac.uk/imgt/hla/	[9]
IEDB	MHC binding peptides, ligands and epitopes	http://www.immuneepitope.org/	[21]
SYFPEITHI	MHC ligands and peptide motif	http://www.syfpeithi.de/	[42]
IPD-MHC	MHC sequences of diverse species	http://www.ebi.ac.uk/ipd/mhc/	[61]
MHCBN	MHC/TAP binding peptides and T-cell epitopes	http://www.imtech.res.in/raghava/mhcbn/	[62]
EPIMHC	MHC ligands	http://bio.dfci.harvard.edu/epimhc/	[63]
LANL-HIV	HIV T-cell epitopes	http://www.hiv.lanl.gov/content/immunology/index	—


MHC-peptide binding 예측 관련 주요 데이터베이스

01 제안이유


■ MHC polymorphism → time & cost consuming

□ MHC-Peptide 면역 반응 관련 데이터가 축적되며, Computational 기반 연구 접근에 용이해짐

- in-vitro → in silico



allele-specific method



pan-specific method

01 제안이유


- MHC-peptide 면역 반응 관련 데이터를 학습해 binding affinity를 예측하는 머신러닝 모델들이 연구되고 있음

Table 1: Availability and utilities of pan-specific methods

Name	URL	Method	Date	MHC				MultiSel	Input	PepLen	Package	Reference
				HLA	!HLA	Extend	Super					
MHC-I pan-specific prediction tools												
ADT	http://atom.research.microsoft.com/hlabinding/hlabinding.aspx	Adaptive double threading	7/2006	ABC	NO	YES	NO	YES	FasPep, FasSeq	9–10	NO	[22]
KISS	http://cbio.ensmp.fr/kiss/	Kernel	12/2007	ABC	NO	NO	YES	YES	Pep	9	YES	[23]
NetMHCpan	http://www.cbs.dtu.dk/services/NetMHCpan/	ANN	11/2008	ABC	YES	YES	YES	YES	Pep, FasSeq	8–11	YES	[24,25]
PickPocket	No public server available	PSSM	3/2009	–	YES	–	–	–	–	–	NO	[26]
MULTIPRED2-I	http://cvc.dfci.harvard.edu/multipred2/HTML/predictionI.php	Integration/NetMHCpan	12/2010	ABC	NO	NO	YES	YES	FasSeq	8–11	NO	[34]
MHC-II pan-specific prediction tools												
TEPITOPE	http://www.imtech.res.in/raghava/propred/	PSSM	7/1999	50 DRs	NO	NO	NO	YES	Seq, FasSeq	9	YES	[27,28]
MHCII Multi	http://www.epitoolkit.org/mhcii multi/	Multi-Instance learning	2008	DR	NO	NO	NO	YES	Seq, FasSeq	≥9	NO	[29]
SIADT	No public server available	Shift-Invariant ADT	9/2008	DR, DP, DQ	YES	–	–	–	–	–	NO	[30]
MultiRTA	http://bordnerlab.org/MultiRTA	RTA [19]	9/2010	DR, DP	NO	NO	NO	NO	Pep	≥9	NO	[31]
NetMHCIIpan-1.0	http://www.cbs.dtu.dk/services/NetMHCIIpan-1.0/	ANN/SMM-align [17]	7/2008	DR	NO	NO	NO	YES	Pep, FasSeq	≥9	YES	[32]
NetMHCIIpan-2.0	http://www.cbs.dtu.dk/services/NetMHCIIpan-2.0/	ANN/NN-align [18]	11/2010	DR	NO	NO	NO	YES	Pep, FasSeqs	≥9	YES	[33]
MULTIPRED2-II	http://cvc.dfci.harvard.edu/multipred2/HTML/prediction2.php	Integration/NetMHCIIpan	12/2010	DR	NO	NO	YES	YES	FasSeq	9	NO	[34]

01 제안이유

- MHC-peptide 면역 반응 관련 데이터를 학습해 binding affinity를 예측하는 머신러닝 모델들이 연구되고 있음
- 실험적으로 검증된 binding affinity 데이터셋 학습 → 펩티드를 binder or non-binder로 분류



02 제안내용

■ DeepAttentionPan 모델 기반 성능 개선

구분	모델	설명	아이디어
pan-specific	NetMHCPan	가장 처음 나온 pan-specific ANN 모델	5-fold CV 25개 모델 Ensemble
	DCNN	DCNN 기반 low-level, high-level 피쳐 추출 모델	DCNN 구조 사용
	DeepSeqPan	DCNN 기반 low-level, high-level 피쳐 추출 모델	2개의 개별 DCNN encoder 사용
	ACME	Attention 기반 DCNN 모델	Attention 모듈 사용 모델 Ensemble 기법 사용
	DeepAttentionPan	<u>Attention</u> , <u>DCNN</u> , <u>K-fold CV</u> , <u>Ensemble</u> , Transfer Learning 사용	


■ DeepAttentionPan 모델 한계

1. 모델구조: DCNN with Attention 구조를 제안했으나 충분히 “Deep”하지 않으며, “Attention” 모듈 및 모델 구조 변형 가능
2. 데이터셋: 적은 학습 데이터셋으로 인한 과적합(over-fitting) 가능성 존재
3. 피쳐표현: MHC와 Peptide 피쳐 인코딩 스키마로 BLOSUM62를 사용했고, 피쳐 표현력의 불충분성 존재

02 제안내용

■ DeepAttentionPan 모델 아키텍처

- CNN Layer
 - High-level feature 추출 목표
- Attention Layer
 - Attention 1 (peptide)
 - Attention 2 (HLA)
- Extractor CNN Block
 - Binding relationship 학습을 위해 사용
 - Binding context vector 출력
- Binding affinity 예측 모듈
 - FC Layer로 구성되어 IC50 값 출력



DeepAttentionPan 모델 아키텍처

02 제안내용

■ 학습 데이터셋

□ IEDB (Immune Epitope DB)

- Training: DeepAttentionPan 모델 학습에 사용
- Testing: 타 모델들과 성능 비교 위해 사용
- Extended testing: 좋은 성능을 낸 이전 연구인 ACME 모델과 성능 비교 위해 사용

□ IMGT/HLA

- HLA Molecule의 서열 정보를 제공하는 데이터셋

Statistic	Training	Testing	Extended testing
Number of total samples	156 844	8855	30 554
Number of total binding samples	40 867	4429	19 872
Binding sample percentage	26.1%	50.0%	65.0%
Number of HLA alleles	95	25	21
Number of datasets	—	61	54

데이터셋 통계

02 제안내용

■ 모델 성능 비교

□ 핵심: DeepAttentionPan과 NetMHCpan4.0 둘 모두 성능이 가장 좋고, 상호보완으로 사용 가능



IEDB reference	Allele	Peptide length	count	Measure	Our method		NetMHCpan 2.8		NetMHCpan 3.0		NetMHCpan 4.0		SMM		ANN 3.4		ANN 4.0		ARB		SMMMPMBEC		IEDB Consensus		NetMHCcons		PickPocket	
					AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC
1 026 371	B*0702	10	19	t1/2	0.9	0.71	0.88	0.69	0.9	0.68	0.9	0.64	0.82	0.61	0.83	0.63	0.95	0.74	0.77	0.54	0.83	0.68	0.83	0.64	0.85	0.66	0.8	0.61
1 026 840	A*3002	9	56	t1/2	0.57	0.12	0.5	0.05	0.48	0.03	0.5	0.05	0.5	0.07	0.55	0.19	0.48	0.07	0.52	0.15	0.53	0.12	0.48	0.07	0.5	0.09	0.47	-0.01
1 029 125	B*2706	9	21	binary	0.79	0.49	0.75	0.42	0.77	0.45	0.73	0.39	-	-	-	-	-	-	-	-	-	-	-	-	0.75	0.42	0.8	0.5
1 027 471	A*0201	9	43	binary	0.82	0.35	0.84	0.38	0.81	0.34	0.81	0.34	0.83	0.36	0.81	0.34	0.84	0.37	0.81	0.35	0.83	0.36	0.82	0.35	0.83	0.36	0.83	0.37
1 026 840	A*2402	9	346	binary	0.83	0.37	0.85	0.39	0.85	0.38	0.85	0.39	0.82	0.36	0.85	0.38	0.85	0.38	0.83	0.37	0.82	0.35	0.84	0.38	0.85	0.39	0.82	0.36
1 031 894	A*0201	9	3	ic50	1	0.5	1	0.5	1	0.5	1	0.5	1	0.5	1	0.5	1	0.5	1	0.5	1	0.5	1	0.87	1	0.5	1	0.5
1 033 071	A*0201	10	65	ic50	0.88	0.78	0.87	0.82	0.91	0.85	0.91	0.85	0.88	0.81	0.9	0.84	0.91	0.86	0.86	0.79	0.89	0.82	0.88	0.85	0.89	0.83	0.87	0.81
1 029 061	B*5701	9	17	ic50	1	0.65	0.97	0.6	1	0.58	0.97	0.56	0.97	0.64	0.87	0.64	0.83	0.6	0.6	0.12	0.97	0.65	0.9	0.62	0.9	0.57	0.97	0.72
1 031 959	B*2705	8	97	binary	0.44	-0.09	0.49	-0.02	0.49	-0.02	0.49	-0.02	0.46	-0.07	0.47	-0.06	0.48	-0.04	0.47	-0.04	0.46	-0.06	0.45	-0.08	0.47	-0.04	0.49	-0.02
1 027 079	A*0201	9	18	binary	0.82	0.49	0.82	0.49	0.82	0.49	0.85	0.54	0.77	0.42	0.78	0.44	0.78	0.44	0.82	0.49	0.77	0.42	0.75	0.4	0.82	0.49	0.82	0.49
1 028 790	A*6802	10	2	ic50	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1
1 026 371	B*0702	9	33	t1/2	0.96	0.81	0.93	0.81	0.97	0.82	0.97	0.82	0.93	0.72	0.93	0.77	0.9	0.72	0.72	0.44	0.93	0.74	0.92	0.72	0.92	0.77	0.85	0.56
1 026 840	A*3002	9	360	binary	0.73	0.37	0.77	0.42	0.78	0.45	0.78	0.45	0.73	0.36	0.75	0.4	0.75	0.4	0.65	0.25	0.72	0.35	0.75	0.4	0.77	0.43	0.75	0.4
⋮																												
1 026 840	A*6801	9	35	ic50	0.87	0.65	0.84	0.63	0.84	0.6	0.85	0.61	0.79	0.62	0.84	0.65	0.85	0.68	0.77	0.53	0.83	0.63	0.82	0.66	0.85	0.65	0.86	0.64
1 028 790	A*0206	10	2	ic50	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1
-	-	-	-	-	21	17	15	9	14	11	21	19	8	7	12	11	20	17	8	9	8	9	8	8	12	12	9	9

61개 allele에 대한 DeepAttentionPan 모델과 벤치마크 알고리즘 성능 비교

02 제안내용

■ 모델 성능 비교

- 핵심: DeepAttentionPan과 NetMHCpan4.0 둘 모두 성능이 가장 좋고, 상호보완으로 사용 가능
- 특징: DeepAttentionPan 모델이 성능이 더 좋은 경우도 존재



02 제안내용

■ 모델 성능 비교

□ 핵심: ACME 보다 DeepAttentionPan이 성능 좋음 (dataset-level, allele-level 모두)

- dataset-level: 23 vs 15 (AUC), 24 vs 22 (SRCC)
- allele-level: 10 vs 5 (AUC), 10 vs 8 (SRCC)

IEDB reference number	Allele	Peptide length	Measure	Count	ACME SRCC	OUR SRCC	ACME AUC	OUR AUC
1 033 576	A*02:01	9	binary	187	0.04	0.08	0.54	0.59
1 031 072	A*02:01	9	ic50	24	0.86	0.83	1	1
1 031 072	A*02:01	10	ic50	16	0.83	0.84	0.87	0.9
1 033 071	A*02:01	9	ic50	102	0.81	0.82	0.86	0.87
1 033 071	A*02:01	10	ic50	65	0.79	0.78	0.91	0.88
1 031 959	B*27:05	8	binary	97	-0.1	-0.09	0.44	0.44
⋮								
1 026 840	B*58:01	9	ic50	34	0.2	0.32	0.62	0.7
1 026 840	B*07:02	9	binary	288	0.33	0.32	0.87	0.86
1 026 840	A*30:02	9	binary	360	0.4	0.37	0.75	0.73
1 026 840	A*30:02	9	ic50	56	0.05	0.11	0.55	0.58
1 026 840	A*68:01	9	binary	436	0.41	0.41	0.89	0.9
1 026 840	A*68:01	9	ic50	35	0.58	0.65	0.79	0.87

DeepAttentionPan 모델 vs ACME 모델

02 제안내용

■ DeepAttentionPan 모델 개선 방안

번호	구분	요소	설명
1	데이터 관점	데이터셋 추가	MHC-peptide 관련 추가 데이터셋 파악
2	모델 관점	다른 아키텍처 사용	Transformer 기반 모델 적용
			self-attention 모듈 적용
		레이어 추가	충분한 학습 가능 하도록 레이어 추가
3	피처 관점	피처 추가	단백질-펩티드의 구조적, 물리-화학적인 특성 등을 MHC-peptide 피처 인코딩 방식에 적용
4	하이퍼 파라미터 관점	옵티마이저	다양한 종류의 optimizer를 통해 성능 개선 여부 확인
		학습률	다양한 범위의 learning rate를 통해 성능 개선 여부 확인
		손실 함수	다양한 범위의 loss function를 통해 성능 개선 여부 확인
		= 최적화	NAS → 하이퍼 파라미터 최적화

02 제안내용

■ DeepAttentionPan 모델 개선 방안

□ 피처 관점


- 각 도구는 상호보완 관계

번호	도구	설명	비고
1	PROFEAT	단백질과 펩티드의 구조 & 물리화학적 피처 추출	2006
2	PyBioMed	분자들의 피처를 계산할 수 있는 파이썬 라이브러리	2018
3	PyProtein	PyBioMed 내에서 단백질 구조와 물리화학적 속성 피처 계산 모듈	5개 그룹, 14개 피처
4	PYDPI	피처가 풍부한 파이썬 기반 도구	6개 그룹, 52개 피처
5	iFeature	피처 클러스터링, selection, 차원축소 알고리즘 통합 패키지	18개 시퀀스 인코딩 체계 53가지 유형의 feature
6	Pfeature	위 도구들의 기능과 많은 protein descriptor를 통합	SOTA

02 제안내용

■ DeepAttentionPan 모델 개선 방안

□ 피처 관점



Pfeature를 통해 계산 가능한 주요 피처 정리

03 활용 방안 및 기대 효과

- MHC-Peptide binding affinity 예측 → 향후 약물 면역 반응 판단 → 후보 물질 스크리닝 → 신약 개발 시간/비용 절감
- protein-protein 결합 또는 protein-DNA/RNA 결합 예측 같은 향후 연구에도 사용 가능
- 펩타이드 길이 검색 알고리즘과 결합 → 지정 결합 강도 도달을 위한 펩타이드 reverse design 가능
- 돌연변이 유발 → 기존 펩타이드 수정 or 알려진 펩타이드 library에서 유망한 펩타이드 후보 스크리닝에 도움

04 참고문헌

Index	Title	Source	Published	Remark
1	Deep learning pan-specific model for interpretable MHC-I peptide binding prediction with improved attention mechanism	PROTEINS	2021.03	Research Paper
2	Toward more accurate pan-specific MHC-peptide binding prediction: a review of current methods and tools	Briefings In Bioinformatics	2011.09	Review paper
3	A comprehensive review and performance evaluation of bioinformatics tools for HLA class I peptide-binding prediction	Briefings In Bioinformatics	2019	Review paper
4	ACME: pan-specific peptide-MHC class I binding prediction through attention-based deep neural networks	Bioinformatics	2019.05	Research Paper
5	Examining the independent binding assumption for binding of peptide epitopes to MHC-I molecules	Bioinformatics	2003	Research Paper
6	Computing wide range of protein/peptide features from their sequence and structure	bioRxiv	2019.04	Feature related Library/Tool
7	iFeature: a Python package and web server for features extraction and selection from protein and peptide sequences	Bioinformatics	2018	Feature related Library/Tool
8	Scheme for ranking potential HLA-A2 binding peptides based on independent binding of individual peptide side-chains	The Journal of Immunology	1985	Background Knowledge
9	The human leucocyte antigen (HLA) system	Vox Sanguinis	2004	Background Knowledge
10	IMMUNOLOGY Kuby 번역학 8판	범에듀케이션	2020.03	Background Knowledge
11	https://github.com/ziqi92/peptide-binding-prediction/blob/master/src/attention.py	Github	-	attention-based model
12	https://github.com/jjin49/DeepAttentionPan	Github	-	DeepAttentionPan Model
13	https://www.thermofisher.com/kr/ko/home/life-science/protein-biology/protein-biology-learning-center/protein-biology-resource-library/pierce-protein-methods/amino-acid-physical-properties.html	Web	-	Peptide/Protein feature
14	https://bio.libretexts.org/Bookshelves/Biochemistry/Book%3ABiochemistry_Free_For_All_(Ahern_Rajagopal_and_Tan)/02%3A_Structure_and_Function/202%3A_Structure_Function_-_Amino_Acids	Web	-	Peptide/Protein feature

Q & A

01 제안이유

■ MHC polymorphism → time & cost consuming

□ MHC-Peptide 면역 반응 관련 데이터가 축적되며, Computational 기반 연구 접근에 용이해짐

- in-vitro → in silico

Data set	Brief	MHC	URL	References
Zhang data sets	HLA Binding and ligand data sets from IEDB and SYFPEITHI (2009)	I	http://www.cbs.dtu.dk/suppl/immunology/pan-eval.php	[55]
Hoof data sets	Non-human binding data set and HLA ligand data sets from in-house, IEDB and SYFPEITHI (2008)	I	http://www.cbs.dtu.dk/suppl/immunology/NetMHCpan-2.0.php	[25]
Peters data sets	MHC-I binding data from IEDB of five species besides human (2006)	I	http://mhcbindingpredictions.immuneepitope.org/	[54]
Heckerman data sets	Binary data from SYFPEITHI, MHCBN, LANL (2006)	I	ftp://ftp.research.microsoft.com/users/heckerma/recomb06/	[64]
Pan-I data sets	T-cell epitopes from IEDB, source protein from Uniprot	I	http://www.biokdd.fudan.edu.cn/Service/panview.htm	
Wang-I.0 data sets	MHC-II binding peptides, PDB structure, Th cell epitopes (2008)	II	http://mhcbindingpredictions.immuneepitope.org/MHCII/	[53]
Wang-2.0 data set	Experimentally measured binding affinities covering 26 HLA and mouse alleles (2010)	II	http://tools.immuneepitope.org/analyze/html/download.MHCII.html	[20]
Nielsen-I.0 data sets	Quantitative peptide binding data in NetMHCIIpan-I.0 (2008)	II	http://www.cbs.dtu.dk/suppl/immunology/NetMHCII-2.0.php	[32]
Nielsen-2.0 data sets	Quantitative peptide binding data, SYFPEITHI ligand data and IEDB epitope data in NetMHCIIpan-2.0 (2010)	II	http://www.cbs.dtu.dk/suppl/immunology/NetMHCIIpan-2.0/	[33]
DFRMLI data sets	Preprocessed and scaled immunological binding and ligand data sets for machine learning (2008.)	I and II	http://bio.dfci.harvard.edu/DFRMLI/	[50, 52]
Pan-II data sets	Binary binding data from IEDB for evaluation	II	http://www.biokdd.fudan.edu.cn/Service/panview.htm	

01 제안이유

- MHC-peptide 면역 반응 관련 데이터를 학습해 binding affinity를 예측하는 머신러닝 모델들이 연구되고 있음



Category	Tool ^a	Year	Software availability ^b	Webserver availability ^b	Max data upload	Step-by-step instruction ^{b,c}	Parameters setting function ^{b,c}	Email of result ^{b,c}	Features	Algorithm ^c	Training-test split ^c	Performance evaluation strategy ^c	Last updated date
Machine learning based	NetMHC 4.0	2014	Yes	Yes	≤5000 sequences and ≤20 000 amino acids	Yes	Yes	Yes	Sequence-based features	NN	4:1	5-fold CV	October 2017
	NetMHCstabpan 1.0	2016	Yes	Yes	≤5000 sequences and ≤20 000 amino acids	Yes	Yes	Yes	Physicochemical features	NN	4:1	5-fold CV, independent test	September 2018
	NetMHCPan 4.0	2017	Yes	Yes	≤5000 sequences and ≤20 000 amino acids	Yes	Yes	Yes	Sequence-based & binary features	NN	4:1	5-fold CV, independent test	January 2018
	MHCnuggets 2.0	2017	Yes	No	N.A.	N.A.	N.A.	N.A.	Sequence-based & physicochemical features	NN	NM	3-fold CV	August 2018
	ConvMHC	2017	No	Yes	N.M.	No	No	No	Sequence-based & physicochemical features	NN	75:1	LOO, 5-fold CV, independent test	July 2018
	HLA-CNN	2017	Yes	No	N.A.	N.A.	N.A.	N.A.	Sequence-based features	NN	7:3	5-fold CV, independent test	August 2017

02 제안내용

■ DeepAttentionPan 모델

□ Attention 1 모듈 (Peptide)

- 핵심: 펩타이드 position weight 계산
- 입력: 펩타이드 인코더의 CNN 출력 값
- 출력: weighted vector (시퀀스 피쳐 + 포지션 중요도)




Attention1 모듈의 position weight 계산 과정

02 제안내용

■ DeepAttentionPan 모델

□ Attention 2 모듈 (MHC)

- 핵심: MHC position weight 계산
- 입력: one-hot 인코딩한 HLA 시퀀스 + HLA feature map
- 출력: weighted vector (시퀀스 피쳐 + 포지션 중요도)



Attention 2 모듈의 weight 계산 과정

02 제안내용


■ DeepAttentionPan 모델 효용성

□ 예측: 펩타이드 위치 별 importance & contribution 계산

- 세 그룹 (9, 10, 11의 길이를 갖는 펩티드)으로 나누어 평균적인 attention weight distribution을 계산

□ 라벨: 다른 연구에서 식별해둔 값 기반

- N-말단 & C-말단: 대부분의 대립유전자에 대한 두 개의 기본 anchor 위치



펩타이드 길이 별 Attention weight distribution

02 제안내용

■ DeepAttentionPan 모델 효용성

□ Transfer Learning

- (이유) HLA allele에 대한 데이터 불균형으로 인해 적은 데이터를 가진 allele는 학습 과정 중 무시될 수 있음
- (목표) fine-tuning을 통해 allele-specific 모델보다 뛰어난 성능의 pan-specific 모델을 만드는 것
- (목적) 적은 수의 데이터를 갖는 allele에 대해서도 예측 모델의 성능을 개선하고자 함

Alleles	Training set size	Pan model		Transferred model				Allele-specific model			
		Average		Average		Std		Average		Std	
		AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC
B*44:03	1404	0.67	0.58	0.70	0.62	0.004	0.007	0.68	0.60	0.0040	0.0172
B*27:03	876	0.92	0.71	0.92	0.71	0.025	0.044	0.51	0.01	0.1851	0.3166
B*38:01	517	—	0.8	—	1.00	—	0.000	—	0.60	—	0.1789
A*66:01	219	0.57	0.08	0.69	0.21	0.012	0.020	0.67	0.19	0.1666	0.1911
B*15:02	164	1	0.71	1.00	0.71	0.000	0.000	0.77	0.38	0.1145	0.1643
C*03:03	154	0.96	0.95	1.00	0.96	0.000	0.004	0.66	0.53	0.0480	0.0882
Average		0.82	0.64	0.86	0.70	0.008	0.013	0.66	0.38	0.1036	0.1594

Transfer Learning을 통한 성능 개선

02 제안내용

04. AIDrug 빅데이터 / AI 신약	
AIDrug.re.kr	
인공지능 모델	설명
ADMET	ADMET 예측 AI 모델 12건
Toxicity 등	독성 등 예측 AI 모델 16건
De novo Design	Scaffold, 물성, 단백질 기반 구조 생성 등 AI 모델 3건
Virtual Screening	약물-단백질 상호작용 예측 등
기타	빅데이터 검색 등

02 제안내용

■ DeepAttentionPan 모델 개선 방안

□ 피처 관점

번호	피처	번호	피처
1	Aliphatic	11	Stability
2	Aromaticity	12	Instability
3	Charge (Density)	13	Antigenicity
4	Hydrophilicity	14	MW monoisotopic
5	Hydrophobicity	15	Relative Surface Accessibility
6	Isoelectric Point	16	Accessible Surface area
7	Molecular Weight	17	Interaction Propensity
8	Polarity	18	Dipeptide
9	Solubility	19	Tripeptide
10	Titration	20	B Turn