

PROTEINS | 2021.02

신약 후보 물질 스크리닝 모델

DeepAttentionPan

MHC-Peptide Binding Affinity Prediction

2022.MM.DD

이 한 얼

CONTENTS

```
graph TD; C[CONTENTS] --- L1[ ]; L1 --- B1[01]; L1 --- B2[02]; L1 --- B3[03]; L1 --- B4[04]; B1 --- B1_K[핵심 요약]; B1_K --- B1_E[Key Summary]; B2 --- B2_K[관련 연구]; B2_K --- B2_E[Related Works]; B3 --- B3_K[논문 요약]; B3_K --- B3_E[Paper Summary]; B4 --- B4_K[개선 방안]; B4_K --- B4_E[Improvement];
```

01

핵심 요약

Key Summary

02

관련 연구

Related Works

03

논문 요약

Paper Summary

04

개선 방안

Improvement

■ 연구 목표 (Goal)

- MHC-peptide binding affinity 예측 모델 제시 → pan-specific 모델 성능 개선

■ 연구 배경 (Motivation)

- (Micro) 이전 연구인 ACME 모델은 attention 메커니즘 구현 제대로 못함 → black-box 기반이며 설명 가능 X
- (Macro) MHC-peptide binding affinity 예측 → 향후 약물 면역 반응 판단 + 펩티드 후보 스크리닝

■ 연구 핵심 (Main)

- **DeepAttentionPan**: DCNN with attention-based model 제시
 - Attention mechanism
 - Transfer Learning
 - Ensemble, K-Fold CV

■ 데이터셋 (dataset)

□ IEDB Dataset (BD 2013 with IC50)

- Training: DeepAttentionPan 모델 학습에 사용
- Testing: IEDB's weekly benchmark → 타 모델과 성능 비교 위해 사용
- Extended testing: ACME 모델 성능 비교 위해 사용

■ 연구 결과 (Result)


→ IEDB's weekly benchmark 데이터셋의 21/25개의 HLA allele에 대해 SOTA 달성

Index	Idea	Description
1	Attention mechanism	펩티드의 position importance를 학습할 수 있음을 보임
2	Transfer Learning	allele-specific + pan-specific 장점 결합 → 특정 allele 데이터에 대해 좋은 성능
3	Ensemble	모델 안정성 + 성능 ↑
4	K-Fold Cross Validation	모델 안정성 + 성능 ↑


■ 연구 흐름

□ in-vitro → in silico

∴ MHC polymorphism → time & cost consuming



allele-specific method



pan-specific method

Table 1: Availability and utilities of pan-specific methods

Name	URL	Method	Date	MHC				MultiSel	Input	PepLen	Package	Reference
				HLA	!HLA	Extend	Super					
MHC-I pan-specific prediction tools												
ADT	http://atom.research.microsoft.com/hlabinding/hlabinding.aspx	Adaptive double threading	7/2006	ABC	NO	YES	NO	YES	FasPep, FasSeq	9–10	NO	[22]
KISS	http://cbio.ensmp.fr/kiss/	Kernel	12/2007	ABC	NO	NO	YES	YES	Pep	9	YES	[23]
NetMHCpan	http://www.cbs.dtu.dk/services/NetMHCpan/	ANN	11/2008	ABC	YES	YES	YES	YES	Pep, FasSeq	8–11	YES	[24,25]
PickPocket	No public server available	PSSM	3/2009	–	YES	–	–	–	–	–	NO	[26]
MULTIPRED2-I	http://cvc.dfc.harvard.edu/multipred2/HTML/prediction1.php	Integration/NetMHCpan	12/2010	ABC	NO	NO	YES	YES	FasSeq	8–11	NO	[34]
MHC-II pan-specific prediction tools												
TEPITOPE	http://www.imtech.res.in/raghava/propred/	PSSM	7/1999	50 DRs	NO	NO	NO	YES	Seq, FasSeq	9	YES	[27,28]
MHCIIIMulti	http://www.epitoolkit.org/mhciimulti/	Multi-Instance learning	2008	DR	NO	NO	NO	YES	Seq, FasSeq	≥9	NO	[29]
SIADT	No public server available	Shift-Invariant ADT	9/2008	DR, DP, DQ	YES	–	–	–	–	–	NO	[30]
MultiRTA	http://bordnerlab.org/MultiRTA	RTA [19]	9/2010	DR, DP	NO	NO	NO	NO	Pep	≥9	NO	[31]
NetMHCIIpan-1.0	http://www.cbs.dtu.dk/services/NetMHCIIpan-1.0/	ANN/SMM-align [17]	7/2008	DR	NO	NO	NO	YES	Pep, FasSeq	≥9	YES	[32]
NetMHCIIpan-2.0	http://www.cbs.dtu.dk/services/NetMHCIIpan-2.0/	ANN/NN-align [18]	11/2010	DR	NO	NO	NO	YES	Pep, FasSeqs	≥9	YES	[33]
MULTIPRED2-II	http://cvc.dfc.harvard.edu/multipred2/HTML/prediction2.php	Integration/NetMHCIIpan	12/2010	DR	NO	NO	YES	YES	FasSeq	9	NO	[34]

allele-specific method

pan-specific method

■ 연구 흐름

□ in-vitro → in silico

- 데이터가 축적되며, computational 접근에 용이해짐

Table 2: Major databases on MHC-peptide binding prediction

Database	Brief	URL	References
IMGT/HLA	HLA sequences	http://www.ebi.ac.uk/imgt/hla/	[9]
IEDB	MHC binding peptides, ligands and epitopes	http://www.immuneepitope.org/	[21]
SYFPEITHI	MHC ligands and peptide motif	http://www.syfpeithi.de/	[42]
IPD-MHC	MHC sequences of diverse species	http://www.ebi.ac.uk/ipd/mhc/	[61]
MHCBN	MHC/TAP binding peptides and T-cell epitopes	http://www.imtech.res.in/raghava/mhcbn/	[62]
EPIMHC	MHC ligands	http://bio.dfci.harvard.edu/epimhc/	[63]
LANL-HIV	HIV T-cell epitopes	http://www.hiv.lanl.gov/content/immunology/index	—

주요 데이터베이스 종류

■ 연구 흐름

□ in-vitro → in silico

- 데이터가 축적되며, computational 접근에 용이해짐


Table 3: Benchmark data sets for evaluating pan-specific methods

Data set	Brief	MHC	URL	References
Zhang data sets	HLA Binding and ligand data sets from IEDB and SYFPEITHI (2009)	I	http://www.cbs.dtu.dk/suppl/immunology/pan-eval.php	[55]
Hoof data sets	Non-human binding data set and HLA ligand data sets from in-house, IEDB and SYFPEITHI (2008)	I	http://www.cbs.dtu.dk/suppl/immunology/NetMHCpan-2.0.php	[25]
Peters data sets	MHC-I binding data from IEDB of five species besides human (2006)	I	http://mhcbindingpredictions.immuneepitope.org/	[54]
Heckerman data sets	Binary data from SYFPEITHI, MHCBN, LANL (2006)	I	ftp://ftp.research.microsoft.com/users/heckerma/recomb06/	[64]
Pan-I data sets	T-cell epitopes from IEDB, source protein from Uniprot	I	http://www.biokdd.fudan.edu.cn/Service/panview.htm	
Wang-I.0 data sets	MHC-II binding peptides, PDB structure, Th cell epitopes (2008)	II	http://mhcbindingpredictions.immuneepitope.org/MHCII/	[53]
Wang-2.0 data set	Experimentally measured binding affinities covering 26 HLA and mouse alleles (2010)	II	http://tools.immuneepitope.org/analyze/html/download.MHCII.html	[20]
Nielsen-I.0 data sets	Quantitative peptide binding data in NetMHCIIpan-I.0 (2008)	II	http://www.cbs.dtu.dk/suppl/immunology/NetMHCII-2.0.php	[32]
Nielsen-2.0 data sets	Quantitative peptide binding data, SYFPEITHI ligand data and IEDB epitope data in NetMHCIIpan-2.0 (2010)	II	http://www.cbs.dtu.dk/suppl/immunology/NetMHCIIpan-2.0/	[33]
DFRMLI data sets	Preprocessed and scaled immunological binding and ligand data sets for machine learning (2008.)	I and II	http://bio.dfci.harvard.edu/DFRMLI/	[50, 52]
Pan-II data sets	Binary binding data from IEDB for evaluation	II	http://www.biokdd.fudan.edu.cn/Service/panview.htm	

■ 연구 흐름

□ Scoring function | Machine Learning | Consensus

- 피쳐 계산: (1) 아미노산 빈도 (2) 펩티드 시퀀스 유사도 (3) 아미노산 포지션 프로파일 → 펩티드 시퀀스 후보 스코어링



■ 연구 흐름

□ Scoring function | Machine Learning | Consensus


- 피쳐 계산: (1) 아미노산 빈도 (2) 펩티드 시퀀스 유사도 (3) 아미노산 포지션 프로파일 → 펩티드 시퀀스 후보 스코어링

Category	Tool ^a	Year	Software availability ^b	Webserver availability ^b	Max data upload	Step-by-step instruction ^{b,c}	Parameters setting function ^{b,c}	Email of result ^{b,c}	Features	Algorithm ^c	Training-test split ^c	Performance evaluation strategy ^c	Last updated date
Scoring function based	SYFPEITHI	1999	No	Yes	Single sequence	No	No	No		PSSM	NM	N.A.	August 2012
	RANKPEP	2002	No	Yes	N.M.	Yes	Yes	No		PSSM	NM	Independent test	January 2019
	PickPocket 1.1	2009	Yes	Yes	≤5000 sequences and ≤20 000 amino acids	Yes	Yes	Yes		PSSM	NM	LOO, 5-fold CV	January 2017
	SMMPMBEC	2009	Yes	Yes	≤200 sequences or ≤10 MB	Yes	No	Yes		PSSM	NM	5-fold CV	January 2014
	PSSMHCpan 1.0	2017	Yes	No	N.A.	N.A.	N.A.	N.A.		PSSM	NM	10-fold CV, independent test	February 2017
	MixMHCpred 2.0.1	2017	Yes	No	N.A.	N.A.	N.A.	N.A.		PSSM	NM	Independent test	August 2018

■ 연구 흐름

□ Scoring function | Machine Learning | Consensus

- 실험적으로 검증된 binding affinity 데이터셋 학습 → 펩티드를 binder or non-binder로 분류



■ 연구 흐름

□ Scoring function | Machine Learning | Consensus


- 실험적으로 검증된 binding affinity 데이터셋 학습 → 펩티드를 binder or non-binder로 분류

Category	Tool ^a	Year	Software availability ^b	Webserver availability ^b	Max data upload	Step-by-step instruction ^{b,c}	Parameters setting function ^{b,c}	Email of result ^{b,c}	Features	Algorithm ^c	Training-test split ^c	Performance evaluation strategy ^c	Last updated date
Machine learning based	NetMHC 4.0	2014	Yes	Yes	≤5000 sequences and ≤20 000 amino acids	Yes	Yes	Yes	Sequence-based features	NN	4:1	5-fold CV	October 2017
	NetMHCstabpan 1.0	2016	Yes	Yes	≤5000 sequences and ≤20 000 amino acids	Yes	Yes	Yes	Physicochemical features	NN	4:1	5-fold CV, independent test	September 2018
	NetMHCPan 4.0	2017	Yes	Yes	≤5000 sequences and ≤20 000 amino acids	Yes	Yes	Yes	Sequence-based & binary features	NN	4:1	5-fold CV, independent test	January 2018
	MHCnuggets 2.0	2017	Yes	No	N.A.	N.A.	N.A.	N.A.	Sequence-based & physicochemical features	NN	NM	3-fold CV	August 2018
	ConvMHC	2017	No	Yes	N.M.	No	No	No	Sequence-based & physicochemical features	NN	75:1	LOO, 5-fold CV, independent test	July 2018
	HLA-CNN	2017	Yes	No	N.A.	N.A.	N.A.	N.A.	Sequence-based features	NN	7:3	5-fold CV, independent test	August 2017

■ 연구 흐름

□ Scoring function | Machine Learning | Consensus

- 펩타이드 결합 예측 모델 앙상블 → 모델 별 예측 결과에 가중치 부여 후 최종 예측 점수 생성



■ 연구 흐름

□ Scoring function | Machine Learning | Consensus

- 펩타이드 결합 예측 모델 앙상블 → 모델 별 예측 결과에 가중치 부여 후 최종 예측 점수 생성

Category	Tool ^a	Year	Software availability ^b	Webserver availability ^b	Max data upload	Step-by-step instruction ^{b,c}	Parameters setting function ^{b,c}	Email of result ^{b,c}	Features	Algorithm ^c	Training-test split ^c	Performance evaluation strategy ^c	Last updated date
Consensus	MHCflurry 1.2.0	2018	Yes	No	N.A.	N.A.	N.A.	N.A.	Sequence-based & binary features	NN	9:1	Independent test	January 2019
	IEDB-AR-Consensus	2012	Yes	Yes	≤200 sequences or ≤10 MB	Yes	No	Yes		Con	NM	Independent data set	May 2012
	NetMHCcons 1.1	2012	Yes	Yes	≤5000 sequences and ≤20 000 amino acids	Yes	Yes	Yes		Con	NM	Independent data set	January 2017

■ 연구 중요성

□ MHC I-Peptide → T-Cell Receptor → 면역 반응

- 펩티드가 면역원성이 되려면 충분한 binding affinity로 MHC와 결합해야 함 ∴ T^{CD8+}

□ binding affinity 예측 = MHC & Peptide의 다형성 이해 → 후보 펩타이드 스크리닝 → 단백질 기반 신약개발




Fig 1. Structure of HLA-A3 with 9-mer peptide

■ 기존 연구 모델

□ DeepAttentionPan 모델 = 기존 pan-specific 모델에서 사용한 방법론 벤치마킹

구분	Model	Description	Ideas
pan-specific	NetMHCPan	가장 처음 나온 pan-specific ANN 모델	교차 검증: 5-fold CV 모델 안정성: 양상불
	DeepSeqPan	CNN → high-level feature 추출 모델	피처 추출: DCNN encoder 2개
	DCNN	CNN → locally-clustered 상호작용 추출 모델	피처 추출: DCNN
	ACME	CNN & attention → feature 추출 모델	성능 증가: Attention 모델 안정성: 양상불
	DeepAttentionPan	<u>Attention</u> , <u>DCNN</u> , <u>Ensemble</u> , <u>K-fold CV</u> , Transfer Learning 사용	

■ 기존 연구 한계

□ ACME의 성능 증가는 attention 모듈이 아닌 CNN Layer

- attention 모듈: position context 인코딩 X → 펩티드 position별 contribution 식별 어려움
- attention 모듈: 출력 값인 feature map은 마지막 FC layer에 입력하기 전에 나오기에 모델 학습에 불충분할 수 있음

■ 기존 연구 모델

□ DeepAttentionPan 모델 = 기존 pan-specific 모델에서 사용한 방법론 벤치마킹

구분	Model	Description	Ideas
pan-specific	63	<code>fc2 = Dense(fc2_size, activation = "relu")(merge_1)</code>	CV
	64	<code>fc3 = Dense(fc3_size, activation = "relu")(fc2)</code>	블
	65	<code>#The attention module</code>	
	66	<code>mhc_attention_weights = Flatten()(TimeDistributed(Dense(1))(mhc_conv_1))</code>	der 2개
	67	<code>pep_attention_weights = Flatten()(TimeDistributed(Dense(1))(pep_conv))</code>	N
	68	<code>mhc_attention_weights = Activation('softmax')(mhc_attention_weights)</code>	ion
	69	<code>pep_attention_weights = Activation('softmax')(pep_attention_weights)</code>	블
	70	<code>mhc_conv_permute = Permute((2, 1))(mhc_conv_1)</code>	
	71	<code>pep_conv_permute = Permute((2, 1))(pep_conv)</code>	
	72	<code>mhc_attention = Dot(-1)([mhc_conv_permute, mhc_attention_weights])</code>	
ACME의 성능 증	73	<code>pep_attention = Dot(-1)([pep_conv_permute, pep_attention_weights])</code>	
	74	<code>#Concatenating the output of the two modules</code>	
	75	<code>merge_2 = Concatenate()([mhc_attention, pep_attention, fc3])</code>	
	76	<code>#Output of the model</code>	
	77	<code>out = Dense(1, activation = "sigmoid")(merge_2)</code>	
	78	<code>model = Model(inputs=[inputs_1, inputs_2], outputs=out)</code>	할 수 있음

■ 기존 연구 한계

□ ACME의 성능 증

- attention 모듈
- attention 모듈

■ 모델 아키텍처 (DeepAttentionPan)

□ Input

- Peptide sequence (BLOSUM62)
- HLA sequence (BLOSUM62)

□ Output

- binding affinity score

□ Tensor

Element	Value
Batch Size	40
Feature channel	23
Peptide length	15 (padded)
HLA length	385 (padded)




Fig 2. DeepAttentionPan 모델 아키텍처

■ 모델 아키텍처 (DeepAttentionPan)

□ DCNN 모듈

- CNN Layer
 - High-level feature 추출 목표
- Attention Layer
 - Attention 1 (peptide)
 - Attention 2 (HLA)
- Extractor CNN Block
 - Binding relationship 학습을 위해 사용
 - binding context vector 출력

□ Binding affinity 예측 모듈

- FC Layer로 구성되어 IC50 값 출력




Fig 2. DeepAttentionPan 모델 아키텍처

■ ATT1 모듈 (Peptide)

- 입력: 펩티드 인코더의 CNN 출력 값
- 출력: weighted vector (시퀀스 피쳐 + 포지션 중요도)
- 핵심: 펩티드 position weight 계산




Fig 3. ATT 1 모듈의 position weight 계산 과정

■ ATT2 모듈 (MHC)

- 입력: one-hot 인코딩한 HLA 시퀀스 + HLA feature map
- 출력: weighted vector (시퀀스 피쳐 + 포지션 중요도)
- 핵심: MHC position weight 계산




Fig 4. ATT 2 모듈의 Weight 계산 과정

■ 데이터셋

□ IEDB

- Training: DeepAttentionPan 모델 학습에 사용
- Testing: IEDB's weekly benchmark → 타 모델과 성능 비교 위해 사용
- Extended testing: ACME 모델 성능 비교 위해 사용

□ IMGT/HLA

- HLA Molecule sequence

Statistic	Training	Testing	Extended testing
Number of total samples	156 844	8855	30 554
Number of total binding samples	40 867	4429	19 872
Binding sample percentage	26.1%	50.0%	65.0%
Number of HLA alleles	95	25	21
Number of datasets	—	61	54

Table 1. 데이터셋 통계

■ 성능 비교

- 데이터셋: testing set 사용 (61개 allele dataset = 8,855개 데이터)
- 핵심: DeepAttentionPan과 NetMHCpan4.0 둘 모두 성능이 가장 좋고, 상호보완으로 사용 가능
- 차이: Deep보다 Net이 조금 더 성능이 높음 → Deep과 달리 auxiliary eluted ligand 데이터셋 추가 사용

IEDB reference	Allele	Peptide length	count	Measure	Our method		NetMHCpan 2.8		NetMHCpan 3.0		NetMHCpan 4.0		SMM		ANN 3.4		ANN 4.0		ARB		SMMPMBEC		IEDB Consensus		NetMHCcons		PickPocket	
					AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC
1 026 371	B*0702	10	19	t1/2	0.9	0.71	0.88	0.69	0.9	0.68	0.9	0.64	0.82	0.61	0.83	0.63	0.95	0.74	0.77	0.54	0.83	0.68	0.83	0.64	0.85	0.66	0.8	0.61
1 026 840	A*3002	9	56	t1/2	0.57	0.12	0.5	0.05	0.48	0.03	0.5	0.05	0.5	0.07	0.55	0.19	0.48	0.07	0.52	0.15	0.53	0.12	0.48	0.07	0.5	0.09	0.47	-0.01
1 029 125	B*2706	9	21	binary	0.79	0.49	0.75	0.42	0.77	0.45	0.73	0.39	-	-	-	-	-	-	-	-	-	-	-	-	0.75	0.42	0.8	0.5
1 027 471	A*0201	9	43	binary	0.82	0.35	0.84	0.38	0.81	0.34	0.81	0.34	0.83	0.36	0.81	0.34	0.84	0.37	0.81	0.35	0.83	0.36	0.82	0.35	0.83	0.36	0.83	0.37
1 026 840	A*2402	9	346	binary	0.83	0.37	0.85	0.39	0.85	0.38	0.85	0.39	0.82	0.36	0.85	0.38	0.85	0.38	0.83	0.37	0.82	0.35	0.84	0.38	0.85	0.39	0.82	0.36
1 031 894	A*0201	9	3	ic50	1	0.5	1	0.5	1	0.5	1	0.5	1	0.5	1	0.5	1	0.5	1	0.5	1	0.5	1	0.87	1	0.5	1	0.5
1 033 071	A*0201	10	65	ic50	0.88	0.78	0.87	0.82	0.91	0.85	0.91	0.85	0.88	0.81	0.9	0.84	0.91	0.86	0.86	0.79	0.89	0.82	0.88	0.85	0.89	0.83	0.87	0.81
1 029 061	B*5701	9	17	ic50	1	0.65	0.97	0.6	1	0.58	0.97	0.56	0.97	0.64	0.87	0.64	0.83	0.6	0.6	0.12	0.97	0.65	0.9	0.62	0.9	0.57	0.97	0.72
1 031 959	B*2705	8	97	binary	0.44	-0.09	0.49	-0.02	0.49	-0.02	0.49	-0.02	0.46	-0.07	0.47	-0.06	0.48	-0.04	0.47	-0.04	0.46	-0.06	0.45	-0.08	0.47	-0.04	0.49	-0.02
1 027 079	A*0201	9	18	binary	0.82	0.49	0.82	0.49	0.82	0.49	0.85	0.54	0.77	0.42	0.78	0.44	0.78	0.44	0.82	0.49	0.77	0.42	0.75	0.4	0.82	0.49	0.82	0.49
1 028 790	A*6802	10	2	ic50	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1	-	1
1 026 371	B*0702	9	33	t1/2	0.96	0.81	0.93	0.81	0.97	0.82	0.97	0.82	0.93	0.72	0.93	0.77	0.9	0.72	0.72	0.44	0.93	0.74	0.92	0.72	0.92	0.77	0.85	0.56
1 026 840	A*3002	9	360	binary	0.73	0.37	0.77	0.42	0.78	0.45	0.78	0.45	0.73	0.36	0.75	0.4	0.75	0.4	0.65	0.25	0.72	0.35	0.75	0.4	0.77	0.43	0.75	0.4

Table 2. 61 alleles에 대한 DeepAttentionPan 모델과 벤치마크 알고리즘 성능 비교

■ 성능 비교

□ 데이터

□ 핵심:

□ 차이:

TABLE 2 (Continued)

IEDB reference	Allele	Peptide length	count	Measure	Our method		NetMHCpan 2.8		NetMHCpan 3.0		NetMHCpan 4.0		SMM		ANN 3.4		ANN 4.0		ARB		SMPMBEC		IEDB Consensus		NetMHCcons		PickPocket	
							AUC	SRCC	AUC	SRCC	AUC	SRCC			AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC
					AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC
1 028 554	B*5701	9	53	ic50	0.84	0.49	0.86	0.62	0.87	0.64	0.88	0.6	0.77	0.33	0.94	0.52	0.96	0.53	0.63	0.12	0.77	0.29	0.77	0.33	0.92	0.56	0.85	0.44
1 031 072	A*0201	9	24	ic50	1	0.83	0.99	0.82	0.99	0.82	1	0.86	1	0.85	1	0.88	1	0.88	1	0.81	1	0.86	1	0.86	1	0.85	0.97	0.77
1 026 840	A*0201	9	22	ic50	0.69	0.3	0.72	0.36	0.72	0.43	0.71	0.4	0.68	0.37	0.63	0.29	0.68	0.37	0.74	0.45	0.66	0.32	0.59	0.2	0.69	0.34	0.71	0.39
1 029 957	B*3801	9	4	ic50	—	0.8	—	1	—	1	—	1	—	0.8	—	0.8	—	1	—	0	—	0.8	—	1	—	1	—	0.8
1 029 125	B*2705	9	21	binary	0.97	0.77	0.96	0.75	0.95	0.73	0.94	0.72	0.91	0.67	0.94	0.72	0.96	0.75	0.88	0.62	0.96	0.75	0.91	0.68	0.96	0.75	0.91	0.67
1 028 790	A*0203	10	2	ic50	—	−1	—	−1	—	−1	—	−1	—	1	—	−1	—	−1	—	−1	—	1	—	−1	—	−1	—	−1
1 026 840	A*3002	9	56	ic50	0.58	0.11	0.48	0.01	0.49	−0.02	0.5	−0.01	0.57	0.12	0.6	0.13	0.54	0.03	0.66	0.27	0.55	0.07	0.57	0.08	0.53	0.05	0.42	−0.1
1 026 840	B*0702	9	288	binary	0.86	0.32	0.87	0.32	0.86	0.32	0.87	0.33	0.88	0.33	0.88	0.33	0.87	0.33	0.85	0.31	0.88	0.33	0.87	0.32	0.87	0.33	0.85	0.31
1 029 824	A*0201	9	77	binary	0.53	0.05	0.55	0.07	0.57	0.1	0.56	0.09	0.57	0.1	0.57	0.11	0.58	0.12	0.52	0.04	0.57	0.1	0.58	0.12	0.56	0.09	0.55	0.08
315 209	C*0304	9	14	t1/2	0.98	0.9	0.91	0.78	1	0.88	1	0.86	—	—	—	—	—	—	—	—	—	—	—	—	0.91	0.78	0.87	0.72
315 174	B*2703	9	10	binary	0.92	0.71	0.92	0.71	0.83	0.57	0.92	0.71	—	—	—	—	—	—	—	—	0.5	nan	—	—	0.92	0.71	0.88	0.64
1 028 928	A*0201	9	11	binary	1	0.67	0.94	0.6	0.94	0.6	0.94	0.6	0.94	0.6	0.94	0.6	0.94	0.6	0.94	0.6	0.94	0.6	0.94	0.6	0.94	0.6	0.92	0.56
1 031 253	B*0702	9	13	ic50	1	0.97	1	0.97	1	0.97	1	0.98	1	0.96	1	0.96	1	0.98	1	0.89	1	0.97	1	0.97	1	0.97	1	0.87
1 028 790	A*0201	10	2	ic50	—	1	—	1	—	1	—	1	—	1	—	1	—	1	—	1	—	1	—	1	—	1	—	1
1 028 554	B*3501	9	56	ic50	0.72	0.35	0.68	0.36	0.67	0.4	0.66	0.36	0.59	0.21	0.57	0.27	0.69	0.27	0.64	0.26	0.53	0.2	0.7	0.29	0.64	0.36	0.5	0.28
1 026 840	A*0201	9	22	t1/2	0.79	0.44	0.73	0.43	0.73	0.46	0.71	0.41	0.74	0.37	0.67	0.29	0.74	0.38	0.69	0.46	0.72	0.33	0.67	0.24	0.71	0.39	0.66	0.39
1 026 840	A*3001	9	347	binary	0.84	0.18	0.81	0.16	0.8	0.16	0.83	0.17	0.79	0.15	0.77	0.14	0.82	0.17	0.71	0.11	0.78	0.15	0.73	0.12	0.79	0.15	0.75	0.13
1 031 959	B*2705	9	4810	binary	0.61	0.17	0.6	0.16	—	—	—	—	0.61	0.17	0.61	0.17	0.61	0.17	0.59	0.15	0.6	0.17	0.6	0.16	0.6	0.17	0.59	0.15
1 026 371	A*0201	9	34	t1/2	0.74	0.4	0.75	0.42	0.74	0.42	0.74	0.42	0.77	0.45	0.76	0.45	0.74	0.41	0.75	0.45	0.76	0.45	0.75	0.42	0.76	0.45	0.72	0.42
1 026 840	A*2402	9	19	ic50	0.69	0.25	0.63	0.18	0.7	0.27	0.69	0.26	0.76	0.39	0.61	0.19	0.63	0.22	0.45	0.03	0.77	0.36	0.75	0.35	0.62	0.17	0.8	0.45
1 027 588	A*0201	9	18	binary	0.86	0.6	0.83	0.56	0.84	0.58	0.83	0.56	0.84	0.58	0.82	0.55	0.86	0.6	0.75	0.43	0.86	0.6	0.83	0.56	0.82	0.54	0.75	0.42
1 029 125	B*2704	9	21	binary	1	0.82	0.94	0.72	0.99	0.8	0.99	0.8	—	—	—	—	—	—	—	—	—	—	—	—	0.94	0.72	0.83	0.53
1 028 553	A*0201	9	22	ic50	0.9	0.55	0.92	0.62	0.85	0.59	0.85	0.57	0.85	0.59	0.91	0.7	0.92	0.63	0.9	0.69	0.83	0.62	0.85	0.58	0.92	0.64	0.83	0.58
315 312	A*3101	9	8	binary	1	0.87	0.88	0.65	0.94	0.76	1	0.87	0.88	0.65	0.88	0.65	0.88	0.65	0.81	0.55	0.88	0.65	0.88	0.65	0.88	0.65	0.88	0.65
1 028 554	B*0702	9	52	ic50	0.87	0.61	0.77	0.62	0.79	0.63	0.8	0.66	0.85	0.66	0.88	0.7	0.83	0.67	0.76	0.65	0.86	0.7	0.82	0.59	0.86	0.73	0.74	0.7
1 026 840	A*6801	9	35	t1/2	0.36	−0.19	0.32	−0.32	0.38	−0.2	0.38	−0.22	0.25	−0.42	0.27	−0.41	0.28	−0.4	0.31	−0.39	0.25	−0.43	0.26	−0.42	0.29	−0.35	0.24	−0.46
1 028 285	A*0201	11	35	t1/2	0.59	0.15	0.7	0.34	0.68	0.36	0.72	0.45	0.81	0.47	0.78	0.39	0.57	0.14	0.66	0.12	0.76	0.31	0.82	0.47	0.76	0.41	0.8	0.53
1 026 840	A*6801	9	35	ic50	0.87	0.65	0.84	0.63	0.84	0.6	0.85	0.61	0.79	0.62	0.84	0.65	0.85	0.68	0.77	0.53	0.83	0.63	0.82	0.66	0.85	0.65	0.86	0.64
1 028 790	A*0206	10	2	ic50	—	1	—	1	—	1	—	1	—	1	—	1	—	1	—	1	—	1	—	1	—	1	—	1
—	—	—	—	—	21	17	15	9	14	11	21	19	8	7	12	11	20	17	8	9	8	9	8	8	12	12	9	9

Note: The last row of the table is the number of the datasets upon which each algorithm achieves the highest scores.

■ 성능 비교 (DeepAttentionPan vs NetMHCpan4.0)

- 핵심: allele-level에서 비교하면 Net보다 Deep이 성능이 좋음
- 장점: 특정 allele 관련 학습 데이터 없이 좋은 성능 냄 (Deep)
 - 예시: HLA-B*39:06, HLA-C*03:03
 - 이유: Attention 모듈 → 중요 position에 집중 → 학습 안정화 + 일반화 성능




Fig 5. AUC 비교

10(승) / 5(패) / 6(무)




Fig 6. SRCC 비교

9(승) / 9(패) / 3(무)

■ 성능 비교 (DeepAttentionPan vs ACME)

- 핵심: ACME보다 DeepAttentionPan이 성능 좋음 (dataset-level, allele-level 모두)
- dataset-level : 23 vs 15 (AUC), 24 vs 22 (SRCC)
- allele-level: 10 vs 5 (AUC), 10 vs 8 (SRCC)

IEDB reference number	Allele	Peptide length	Measure	Count	ACME SRCC	OUR SRCC	ACME AUC	OUR AUC
1 033 576	A*02:01	9	binary	187	0.04	0.08	0.54	0.59
1 031 072	A*02:01	9	ic50	24	0.86	0.83	1	1
1 031 072	A*02:01	10	ic50	16	0.83	0.84	0.87	0.9
1 033 071	A*02:01	9	ic50	102	0.81	0.82	0.86	0.87
1 033 071	A*02:01	10	ic50	65	0.79	0.78	0.91	0.88
1 031 959	B*27:05	8	binary	97	-0.1	-0.09	0.44	0.44
1 031 959	B*27:05	9	binary	13 540	0.16	0.17	0.6	0.6
1 031 959	B*27:05	10	binary	7663	0.2	0.19	0.63	0.63
1 031 959	B*27:05	11	binary	5330	0.24	0.23	0.66	0.66
1 031 253	A*03:01	9	ic50	14	0.79	0.76	0.91	0.93
1 031 253	B*07:02	9	ic50	13	0.95	0.97	1	1
1 031 253	B*27:05	9	ic50	12	0.63	0.39	0.66	0.54

Table 3. DeepAttentionPan 모델 & ACME 모델 성능 비교

■ Attention 모듈 효용성 입증

□ 예측: 펩티드 position별 importance & contribution 계산

- 세 그룹 (9, 10, 11의 길이를 갖는 펩티드)으로 나누어 평균적인 attention weight distribution을 계산

□ 라벨: 다른 연구에서 식별해둔 값 기반

- N-말단 & C-말단: 대부분의 대립유전자에 대한 두 개의 기본 anchor 위치





Fig 7. Attention weight distribution grouped by peptide length

■ Attention 모듈 효용성 입증

- 예측: 펩티드 position별 importance & contribution 계산
 - 세 그룹 (9, 10, 11의 길이를 갖는 펩티드)으로 나누어 평균적인 attention weight distribution을 계산
- 라벨: 다른 연구에서 식별해둔 값 기반
 - N-말단 & C-말단: 대부분의 대립유전자에 대한 두 개의 기본 anchor 위치




■ Attention 모듈 효용성 입증

□ 예측: 펩티드 position별 importance & contribution 계산

- 세 그룹 (9, 10, 11의 길이를 갖는 펩티드)으로 나누어 평균적인 attention weight distribution을 계산


□ 라벨: 다른 연구에서 식별해둔 값 기반

- N-말단 & C-말단: 대부분의 대립유전자에 대한 두 개의 기본 anchor 위치



■ Attention 모듈 효용성 입증

- 예측: 펩티드 position별 importance & contribution 계산
 - 세 그룹 (9, 10, 11의 길이를 갖는 펩티드)으로 나누어 평균적인 attention weight distribution을 계산
- 라벨: 다른 연구에서 식별해둔 값 기반
 - N-말단 & C-말단: 대부분의 대립유전자에 대한 두 개의 기본 anchor 위치



■ Attention 모듈 효용성 입증

□ 예측: 펩티드 position별 importance & contribution 계산

- 세 그룹 (9, 10, 11의 길이를 갖는 펩티드)으로 나누어 평균적인 attention weight distribution을 계산

□ 라벨: 다른 연구에서 식별해둔 값 기반

- N-말단 & C-말단: 대부분의 대립유전자에 대한 두 개의 기본 anchor 위치




Fig 7. 펩티드 길이 별 Attention weight 분포

■ Attention 모듈 효용성 입증

□ 라벨: 다른 연구에서 식별해둔 값 기반

- N-말단 & C-말단: 대부분의 대립유전자에 대한 두 개의 기본 anchor 위치




Fig 8. 펩티드 positional weight 분포 for HLA allele


■ ATT2_ALL

□ 구조

- 1 FC layer + feature map + **positional matrix**

□ 특징

- N-말단 C-말단 포착 O
- 한계: 길이 다른 펩티드 말단을 동적 포착 X



■ ATT3_ALL

□ 구조

- 1 FC layer + feature map

□ 특징

- 통제 그룹 (ACME와 유사하게 만듦)
- 서로 다른 position의 important를 구분 X




Fig 9. 펩티드 길이 별 Attention weight distribution 비교

■ Attention 모듈 성능 비교

- 베이스라인: NO_ATT
- 실험: 20 ensemble + 10-fold cross-validation
- 성능 증가: DeepAttentionPan, ATT2_ALL
- 성능 감소: ATT3_ALL

Experiment	DeepAttentionPan AUC	DeepAttentionPan SRCC	ATT2_ALL AUC	ATT2_ALL SRCC	ATT3_ALL AUC	ATT3_ALL SRCC	NO_ATT AUC	NO_ATT SRCC
1	0.807	0.505	0.801	0.490	0.791	0.487	0.794	0.490
2	0.808	0.507	0.803	0.501	0.788	0.491	0.788	0.482
3	0.809	0.511	0.801	0.494	0.791	0.486	0.792	0.491
4	0.805	0.506	0.801	0.495	0.784	0.482	0.792	0.483
5	0.808	0.503	0.801	0.492	0.788	0.482	0.791	0.499
Average	0.808	0.506	0.801	0.495	0.788	0.485	0.791	0.489
Std	0.001	0.002	0.001	0.004	0.002	0.003	0.002	0.006

TABLE 4. Attention 모듈 3개에 대한 성능 비교 (testing set)

■ Transfer Learning

□ 학습 배경

- (이유) HLA allele에 대한 데이터 불균형으로 인해 적은 데이터를 가진 allele는 학습 과정 중 무시될 수 있음
- (목표) fine-tuning을 통해 allele-specific 모델보다 뛰어난 성능의 pan-specific 모델을 만드는 것
- (목적) 적은 수의 데이터를 갖는 allele에 대해서도 예측 모델의 성능을 개선하고자 함

□ 학습 관련 정보

구분	항목	값	비고
학습 데이터	training data	156,844	156,844 $\approx$ 95 x 1,650
	number of alleles	95	-
	average sample per allele	$\approx$ 1,650	100 이상 1650 이하의 대립 유전자만 선택
하이퍼 파라미터	learning rate	0.005	기본 learning rate인 0.2보다 보다 작음
	Model	20	각각의 allele를 20개 모델에 학습 후 앙상블 값 출력

■ 성능 비교

□ Transfer Learning 모델 vs allele-specific 모델

- pan-specific + transfer learning 모델 성능이 더 우수 & 표준 편차 더 적음 → more stable
- 5번 반복 실험의 평균값 (transfer learning, allele-specific)

Alleles	Training set size	Pan model		Transferred model				Allele-specific model			
		Average		Average		Std		Average		Std	
		AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC	AUC	SRCC
B*44:03	1404	0.67	0.58	0.70	0.62	0.004	0.007	0.68	0.60	0.0040	0.0172
B*27:03	876	0.92	0.71	0.92	0.71	0.025	0.044	0.51	0.01	0.1851	0.3166
B*38:01	517	—	0.8	—	1.00	—	0.000	—	0.60	—	0.1789
A*66:01	219	0.57	0.08	0.69	0.21	0.012	0.020	0.67	0.19	0.1666	0.1911
B*15:02	164	1	0.71	1.00	0.71	0.000	0.000	0.77	0.38	0.1145	0.1643
C*03:03	154	0.96	0.95	1.00	0.96	0.000	0.004	0.66	0.53	0.0480	0.0882
Average		0.82	0.64	0.86	0.70	0.008	0.013	0.66	0.38	0.1036	0.1594

TABLE 5. Transfer Learning을 통한 성능 개선

■ 연구 결론

□ 성능 우수

- 기존 pan-specific 모델과 비교를 통해 성능 우위 보임 (특히 ACME, NetMHCPan4.0)
- Transfer Learning을 통해 allele-specific 보다 좋은 성능을 보여줌 (even unseen data)
- 다양한 HLA allele 데이터셋에 대해 SOTA 달성

□ 모델 특징

- attention 모듈을 통해 다양한 길이의 펩티드의 중요 binding position 학습 가능 → 모델이 스스로 biological insight를 찾음

■ 향후 연구

- 어텐션 메커니즘을 통해 protein-protein 결합 또는 protein-DNA/RNA 결합 예측 같은 향후 연구에도 사용 O
- 모델이 펩티드 길이 검색 알고리즘과 결합 → 지정 결합 강도 도달을 위한 펩티드 reverse design 가능
- 돌연변이 유발 → 기존 펩티드 수정 or 알려진 펩티드 library에서 유망한 펩티드 후보 스크리닝에 도움

■ 개선 방안

우선 순위	구분	요소	설명
1	데이터 관점	데이터셋 추가	1. Auxiliary eluted ligand dataset 추가 (가능성 검토 필요) 2. MHC-peptide DB 재 검수를 통해 사용 가능한 추가 데이터 파악
		피처 추가	펩티드/단백질의 구조적, 물리-화학적인 특성을 통해 MHC-peptide 결합 예측에 피처로 추가
2	모델 관점	Attention 모듈 변경	attention weight 값을 smoothing하는 과정 추가
		DCNN, FC Layer 추가	1. 충분한 학습 가능 하도록 레이어 추가 (DCNN) 2. 충분한 학습 가능 하도록 레이어 추가 (FC Layer)
		다른 아키텍처 사용	Transformer 기반 모델 적용
3	하이퍼 파라미터 관점	옵티마이저	다양한 종류의 Optimizer를 통해 성능 개선 여부 확인
		학습률	다양한 범위의 learning rate를 통해 성능 개선 여부 확인
		손실 함수	다양한 범위의 loss function를 통해 성능 개선 여부 확인
		기타	NAS → 하이퍼 파라미터 최적화

■ 개선 방안

□ 데이터 관점 - 피쳐 추가




Fig 1. Pfeature를 통해 계산 가능한 주요 피쳐 정리

■ 개선 방안

□ 데이터 관점 - 피처 추가

Index	Feature	Index	Feature
1	Aliphatic	11	Stability
2	Aromaticity	12	Instability
3	Charge (Density)	13	Antigenicity
4	Hydrophilicity	14	MW monoisotopic
5	Hydrophobicity	15	Relative Surface Accessibility
6	Isoelectric Point	16	Accessible Surface area
7	Molecular Weight	17	Interaction Propensity
8	Polarity	18	Dipeptide
9	Solubility	19	Tripeptide
10	Titration	20	B Turn

■ 펩티드/단백질 피처 추출 도구

□ 각 도구는 상호보완 관계

- Pfeature: 단백질/펩티드의 시퀀스, 구조, 물리화학적 특성을 분석하는 파이썬 패키지 (functional level + residue level)

Index	Tool	Description	Remark
1	PROFEAT	단백질과 펩티드의 구조 & 물리화학적 피처 추출	2006
2	PyBioMed	분자들의 피처를 계산할 수 있는 파이썬 라이브러리	2018
3	PyProtein	PyBioMed 내에서 단백질 구조와 물리화학적 속성 피처 계산 모듈	5개 그룹, 14개 피처
4	PYDPI	피처가 풍부한 파이썬 기반 도구	6개 그룹, 52개 피처
5	iFeature	피처 클러스터링, selection, 차원축소 알고리즘 통합 패키지	18개 시퀀스 인코딩 체계 53가지 유형의 feature
6	Pfeature	PROFEAT의 대체제 X 보완제 O 위 도구들의 기능과 많은 protein descriptor를 통합	SOTA

Reference

■ Paper & Book

Index	Title	J/C	Published	Remark
1	Toward more accurate pan-specific MHC-peptide binding prediction: a review of current methods and tools	Briefings In Bioinformatics	2011.09	Review paper
2	A comprehensive review and performance evaluation of bioinformatics tools for HLA class I peptide-binding prediction	Briefings In Bioinformatics	2019	Review paper
3	ACME: pan-specific peptide-MHC class I binding prediction through attention-based deep neural networks	Bioinformatics	2019.05	Research Paper
4	Examining the independent binding assumption for binding of peptide epitopes to MHC-I molecules	Bioinformatics	2003	Research Paper
5	Computing wide range of protein/peptide features from their sequence and structure	bioRxiv	2019.04	Feature related Library/Tool
6	iFeature: a Python package and web server for features extraction and selection from protein and peptide sequences	Bioinformatics	2018	Feature related Library/Tool
7	Scheme for ranking potential HLA-A2 binding peptides based on independent binding of individual peptide side-chains	The Journal of Immunology	1985	Background Knowledge
8	The human leucocyte antigen (HLA) system	Vox Sanguinis	2004	Background Knowledge
9	생명과학을 위한 딥러닝	에이콘	2020.08	Background Knowledge
10	IMMUNOLOGY Kuby 번역학 8판	범에듀케이션	2020.03	Background Knowledge
11	가볍게 읽는 유기화학	북스힐	2020.08	Background Knowledge



Reference

■ Feature & Model

Index	URL	Source	Published	Remark
1	https://github.com/ziqi92/peptide-binding-prediction/blob/master/src/attention.py	Github	-	attention-based model
2	https://github.com/facebookresearch/esm	Github	-	Protein Pretrained model
3	https://www.kaggle.com/code/futurecorporation/covid-19-sars-b-cells-basic-predictions-and-eda	Kaggle	-	Peptide/Protein feature
4	https://www.kaggle.com/code/nageshsingh/coronavirus-covid-19-mers-and-sars-dna-analysis	Kaggle	-	Peptide/Protein feature
6	https://partrita.github.io/posts/solubility/	Github	-	Peptide/Protein feature
7	https://m.blog.naver.com/coco_012/221867676559	Naver	-	Peptide/Protein feature
8	https://en.wikipedia.org/wiki/Amino_acid	Wikipedia	-	Peptide/Protein feature
9	https://www.thermofisher.com/kr/ko/home/life-science/protein-biology/protein-biology-learning-center/protein-biology-resource-library/pierce-protein-methods/amino-acid-physical-properties.html	Web	-	Peptide/Protein feature
10	https://bio.libretexts.org/Bookshelves/Biochemistry/Book%3A_Biochemistry_Free_For_All_(Ahern_Rajagopal_and_Tan)/02%3A_Structure_and_Function/202%3A_Structure_Function_-_Amino_Acids	Web	-	Peptide/Protein feature

Reference

■ Paper & Book





Q & A

■ ACME's attention 레이어 동작

□ $w = b + Fa$


1. Feature map의 각 행 → attention 레이어의 입력

2. attention 레이어의 출력 → weight

즉, attention 레이어 → feature map을 attention 가중치 벡터 w 로 매핑

□ $F_{avg} = \sum_j w'_j F_j$

- 모든 row vector에 대한 가중 평균 계산
- F_{avg} 은 attention module의 출력
- a = attention 레이어의 가중치
- b = corresponding bias
- Softmax: $w_j \rightarrow w'_j$ 로 정규화



■ 모델 학습

□ 라벨 정규화

- IC50값 로그 스케일링 → $Score = 1 - \frac{(1 - \log IC50)}{\log(50000)}$ 로 정규화.
- 학습: 로그 스케일링 값 사용 / 추론: original IC50로 재 변경

□ 모델 정보

Category	Type	Value
Model	Algorithm	DCNN, Attention
Hyperparameter	Optimizer	SGD
	Learning rate	0.2
	Scheduler	ReduceLROnPlateau
	Batch Size	40
Performance	Ensemble	20 model
	K-Fold cross-validation	10
Metric	Main evaluation	AUC
	Sub evaluation	SRCC